

MongoDB és eXistDB összehasonlító teljesítményvizsgálata

FÖLDI BALÁZS

Bevezetés	2
A tesztrendszer tervezése	3
A vizsgálat célja	3
A vizsgált adatbázisok	3
Tesztelt műveletek	4
Mérőszámok	5
Implementációs környezet	5
Tesztadatbázis megvalósítása	6
Adatmodell	6
MongoDB adatstruktúra	7
eXistDB XML struktúra	7
Adatgenerálás	8
A benchmark rendszer implementációja	9
Projekt struktúra	9
Adatgeneráló modul	10
MongoDB kliens implementáció	10
eXistDB kliens implementáció	11
Benchmark tesztek	12
Tesztkörnyezet	12
Insert benchmark	13
Find benchmark	14
Filter benchmark	16
Aggregation benchmark	17
Update benchmark	18
Indexed Find benchmark	20
Általános megfigyelések	21
Összegzés	22

Bevezetés

A modern alkalmazások egyre nagyobb mennyiségű adatot kezelnek, ezért kiemelten fontos az adatbázis-kezelő rendszerek teljesítményének és hatékonyságának vizsgálata. Az eltérő adatmodellek és tárolási megközelítések jelentős különbségeket eredményezhetnek a különböző műveletek végrehajtási idejében, skálázhatóságában és erőforrásigényében. Emiatt az adatbázis kiválasztása kulcsfontosságú szerepet játszik egy rendszer teljesítményében és megbízhatóságában.

A projekt célja két modern NoSQL adatbázis-kezelő rendszer, a MongoDB és az eXistDB összehasonlítása különböző adatkezelési műveletek teljesítménye alapján. A MongoDB dokumentum-orientált adatbázis, amely BSON formátumban tárolja az adatokat, és elsősorban nagy teljesítményű általános célú adatkezelésre optimalizált. Ezzel szemben az eXistDB natív XML adatbázis, amely XML dokumentumok tárolására és XQuery alapú feldolgozására specializálódott.

A vizsgálat során az alábbi szempontok kerülnek elemzésre:

- adatok beszúrásának sebessége,
- egyszerű lekérdezések teljesítménye,
- feltételes szűrések hatékonysága,
- aggregációs műveletek futási ideje,
- rekordok módosításának teljesítménye,
- indexelés hatása a keresésekre.

A benchmark tesztek célja annak bemutatása, hogy a dokumentum-orientált és XML-alapú adatbázisok milyen különbségeket mutatnak különböző terhelések és műveletek esetén. A mérések során azonos adatkészlet és azonos logikai műveletek kerülnek felhasználásra mindkét adatbázisban, így az eredmények objektíven összehasonlíthatók.

A projekt során egy automatizált benchmark rendszer készült TypeScript és Node.js környezetben, amely képes különböző méretű adathalmazokon végrehajtani a teszteket. A mérési eredmények CSV formátumban kerültek rögzítésre, majd diagramok és statisztikai elemzések segítségével kerültek kiértékelésre.

A tesztek különböző méretű adatállományokon futottak, így vizsgálhatóvá vált az adatbázisok viselkedése növekvő terhelés mellett is. Az eredmények alapján következtetések vonhatók le arra vonatkozóan, hogy melyik adatbázis milyen felhasználási területen nyújt előnyösebb teljesítményt.

A tesztrendszer tervezése

A vizsgálat célja

A tesztrendszer célja két modern NoSQL adatbázis-rendszer teljesítményének összehasonlítása különböző adatkezelési műveletek alapján:

- MongoDB
- eXistDB

A vizsgálat során ugyanazon adatkészlet és azonos logikai műveletek kerülnek végrehajtásra mindkét adatbázisban annak érdekében, hogy az eredmények objektíven összehasonlíthatók legyenek. A benchmark rendszer különböző méretű adathalmazokon futtatja a teszteket, így nemcsak az egyes műveletek sebessége, hanem az adatbázisok skálázhatósága és terhelhetősége is vizsgálhatóvá válik.

A projekt célja továbbá annak bemutatása, hogy a különböző adattárolási modellek – dokumentum-orientált BSON alapú tárolás és XML alapú dokumentumtárolás – milyen hatással vannak a teljesítményre. A mérések segítségével következtetések vonhatók le arra vonatkozóan, hogy mely adatbázis milyen felhasználási környezetben alkalmazható hatékonyabban.

A vizsgált adatbázisok

MongoDB

A MongoDB egy dokumentum-orientált NoSQL adatbázis-kezelő rendszer, amely BSON (Binary JSON) formátumban tárolja az adatokat. A rendszer rugalmas sémakezelést biztosít, ezért jól alkalmazható dinamikusan változó vagy strukturálatlan adatok esetén.

A MongoDB egyik legfontosabb előnye a gyors CRUD műveletek támogatása és a hatékony indexelési mechanizmus. Az adatbázis horizontálisan is jól skálázható, ezért széles körben használják nagy terhelésű webes és felhőalapú rendszerekben.

A benchmark során a MongoDB-ben kollekciók kerültek létrehozásra, amelyekben a tesztadatok JSON dokumentumok formájában tárolódtak. A lekérdezések JavaScript alapú MongoDB API segítségével történtek.

eXistDB

Az eXistDB egy natív XML adatbázis-kezelő rendszer, amely XML dokumentumok tárolására és feldolgozására specializálódott. Az adatbázis XQuery és XPath nyelveket használ lekérdezések végrehajtására.

Az eXistDB különösen előnyös olyan rendszerek esetén, ahol az adatok hierarchikus szerkezetűek, illetve ahol fontos az XML dokumentumok natív kezelése. Az XML alapú tárolás ugyanakkor nagyobb feldolgozási költséggel járhat, ami hatással lehet a teljesítményre nagy adatmennyiség esetén.

A benchmark rendszerben az eXistDB REST API-n keresztül került elérésre, a lekérdezések pedig XQuery segítségével valósultak meg.

Tesztelt műveletek

A benchmark rendszer több különböző adatkezelési művelet teljesítményét vizsgálja. A tesztek célja annak meghatározása, hogy az egyes adatbázisok hogyan viselkednek különböző terhelési helyzetekben.

Művelet	Leírás
Insert	Nagy mennyiségű adat beszúrása
Find	Egy konkrét rekord keresése
Filter	Feltételes szűrés végrehajtása
Aggregation	Összesítő lekérdezések futtatása
Update	Dokumentumok módosítása
Indexed Find	Indexelt keresések teljesítménye

Insert

Az insert benchmark célja nagy mennyiségű rekord adatbázisba történő beszúrásának vizsgálata. Ez jól mutatja az adatbázis írási teljesítményét és a dokumentumok feldolgozásának költségét.

Find

A find teszt egy konkrét rekord egyszerű keresésének futási idejét méri. Ez a művelet az egyik leggyakoribb adatbázis-művelet, ezért kiemelten fontos a teljesítménye.

Filter

A filter benchmark feltételes lekérdezések végrehajtását vizsgálja. A tesztek során különböző mezők alapján történik szűrés, például évszám vagy értékelés alapján.

Aggregation

Az aggregation teszt összesítő műveleteket vizsgál, például átlagok számítását vagy csoportosítást. Ezek a műveletek összetettebb adatfeldolgozást igényelnek, ezért jól mutatják az adatbázis lekérdező motorjának hatékonyságát.

Update

Az update benchmark rekordok módosításának teljesítményét méri. A teszt során meglévő dokumentumok egyes mezői kerülnek frissítésre.

Indexed Find

Az indexed find teszt az indexelés hatását vizsgálja a keresési műveletek teljesítményére. Az eredmények alapján összehasonlítható, hogy az indexek milyen mértékben gyorsítják a lekérdezéseket.

Mérőszámok

A benchmark rendszer a teljesítmény mérésére több különböző mérőszámot használ.

A legfontosabb mérőszám a futási idő, amely milliszekundumban (ms) került rögzítésre. Az egyes tesztek több alkalommal is lefutottak, így az eredmények átlagolhatók voltak a pontosabb összehasonlítás érdekében.

A vizsgált mérőszámok:

- futási idő (ms),
- átlagos végrehajtási idő,
- minimum futási idő,
- maximum futási idő,
- indexelés hatása,
- skálázódás növekvő adatmennyiség mellett.

A mérések különböző méretű adathalmazokon történtek, például:

- 100 rekord,
- 1 000 rekord,
- 10 000 rekord,
- 50 000 rekord.

Ez lehetővé tette annak vizsgálatát, hogy az adatbázisok teljesítménye hogyan változik nagyobb terhelés esetén.

Implementációs környezet

A benchmark rendszer TypeScript és Node.js környezetben került implementálásra. A tesztek automatizált benchmark runner segítségével futottak, amely CSV formátumban mentette az eredményeket.

Elem	Érték
Operációs rendszer	Windows / Linux
Programozási nyelv	TypeScript
Futtatókörnyezet	Node.js
MongoDB kliens	MongoDB Node.js Driver
eXistDB kommunikáció	REST API
Adatformátum	JSON / XML
Eredmény export	CSV
Diagramkészítés	Python

A tesztek azonos hardver- és szoftverkörnyezetben kerültek végrehajtásra annak érdekében, hogy az eredmények összehasonlíthatók legyenek.

Tesztadatbázis megvalósítása

Adatmodell

A benchmark tesztek egy könyv adatbázison történtek. Az adatmodell célja egy olyan általános dokumentumalapú struktúra kialakítása volt, amely mind MongoDB, mind eXistDB környezetben hatékonyan reprezentálható.

A könyvek több különböző típusú adatmezőt tartalmaznak:

- szöveges mezőket,
- numerikus értékeket,
- kategóriákat,
- valamint értékelési adatokat.

Ez lehetővé teszi különböző típusú lekérdezések és aggregációs műveletek végrehajtását a benchmark során.

A könyvek az alábbi mezőket tartalmazzák:

Mező	Jelentés
id	Egyedi azonosító
title	Könyv címe
author	Szerző neve
genre	Műfaj
year	Kiadás éve
pages	Oldalszám
price	Ár
rating	Értékelés

Az adatmodell kialakításánál fontos szempont volt, hogy:

- alkalmas legyen nagy mennyiségű rekord generálására,
- támogassa az összetett lekérdezéseket,
- különböző típusú műveleteket lehessen rajta vizsgálni,
- valamint mind JSON, mind XML formátumban egyszerűen reprezentálható legyen.

MongoDB adatstruktúra

A MongoDB dokumentum-orientált adatmodellje BSON dokumentumokat használ. A benchmark során minden könyv egy külön dokumentumként került tárolásra egy kollekcióban.

Példa dokumentum:

```
{
  "title": "Database Systems",
  "author": "John Smith",
  "genre": "Technology",
  "year": 2020,
  "pages": 450,
  "price": 39.99,
  "rating": 4.7
}
```

A MongoDB előnye, hogy a dokumentumok rugalmas szerkezetűek, így nem szükséges előre rögzített séma használata. Ez különösen előnyös dinamikusan változó vagy részben strukturált adatok esetén.

A benchmark rendszerben a rekordok egy books nevű kollekcióban kerültek tárolásra. A lekérdezések MongoDB Node.js driver segítségével történtek.

A tesztek során egyes mezőkre indexek is létrehozásra kerültek, például:

- title,
- genre,
- year.

Az indexelés célja a keresési teljesítmény javítása és az indexed benchmark vizsgálata volt.

eXistDB XML struktúra

Az eXistDB XML alapú adatmodellt használ, ezért minden könyv XML dokumentum formájában került tárolásra.

Példa XML dokumentum:

```
<book>
  <title>Database Systems</title>
  <author>John Smith</author>
  <genre>Technology</genre>
  <year>2020</year>
  <pages>450</pages>
  <price>39.99</price>
  <rating>4.7</rating>
</book>
```

Az XML struktúra jól reprezentálja a hierarchikus adatokat, valamint támogatja az XPath és XQuery alapú lekérdezéseket.

Az eXistDB-ben a dokumentumok egy gyűjteményben (collection) kerültek tárolásra. A lekérdezések REST API-n keresztül futottak, XQuery nyelv használatával.

Az XML alapú adattárolás előnye:

- jól strukturált dokumentumkezelés,
- szabványos adatcsere-formátum,
- összetett hierarchikus struktúrák támogatása.

Hátránya ugyanakkor, hogy az XML feldolgozása nagyobb memória- és processzorigénnyel járhat, különösen nagy mennyiségű adat esetén.

Adatgenerálás

A benchmark tesztekhez szükséges adatok automatikusan generált rekordokból készültek. Az automatikus adatgenerálás lehetővé tette nagy mennyiségű tesztadat gyors és konzisztens előállítását.

A generálás fő céljai:

- nagy mennyiségű tesztadat előállítása,
- konzisztens benchmark környezet biztosítása,
- azonos adatkészlet használata mindkét adatbázisban,
- különböző adatmennyiségek vizsgálata,
- reprodukálható tesztkörnyezet létrehozása.

A generált adatok véletlenszerű, de valósághű értékeket tartalmaztak:

- különböző könyvcímek,
- szerzőnevek,
- műfajok,
- évszámok,
- árak,
- értékelések.

Ez lehetővé tette annak vizsgálatát, hogyan változik az adatbázisok teljesítménye növekvő adatmennyiség mellett.

A generált rekordok először JavaScript objektumként készültek el, majd:

- MongoDB esetén JSON/BSON dokumentummá,
- eXistDB esetén XML dokumentummá

alakultak át.

Az XML konverzió külön modul segítségével történt, amely automatikusan létrehozta a megfelelő XML struktúrát minden rekordhoz.

A benchmark rendszer implementációja

Projekt struktúra

A benchmark rendszer moduláris felépítésben készült TypeScript és Node.js környezetben. A projekt különálló komponensekre bontva tartalmazza az adatgenerálást, az adatbázis-klienseket, a benchmark teszteket és az eredmények kezelését.

A projekt struktúrája:

```
project/
├── generators/
├── mongodb/
├── existdb/
├── benchmark/
├── results/
└── index.ts
```

Az egyes mappák feladatai:

Mappa	Funkció
generators	Tesztadatok generálása
mongodb	MongoDB kliens és benchmark műveletek
existdb	eXistDB kliens és XQuery műveletek
benchmark	Benchmark runner és mérési logika
results	CSV eredmények és diagramok
index.ts	A teljes benchmark rendszer indítása

A moduláris felépítés előnye, hogy:

- a benchmarkok könnyen bővíthetők,
- az adatbázis-kezelő logika elkülönül,
- egyszerűbb az új tesztek hozzáadása,
- valamint a rendszer könnyebben karbantartható.

Adatgeneráló modul

A generators mappa tartalmazza a tesztadatok előállításáért felelős modulokat. Ezek a modulok automatikusan generálnak nagy mennyiségű könyv rekordot különböző mezőértékekkel.

A generálás során:

- véletlenszerű címek,
- szerzők,
- műfajok,
- évszámok,
- árak,
- értékelések

kerülnek előállításra.

Az adatgeneráló rendszer célja olyan valóság-hű adathalmaz létrehozása, amely megfelelően terheli az adatbázisokat a benchmark során.

MongoDB kliens implementáció

A MongoDB kezeléséért külön modul felel. Ebben történik:

- az adatbázis-kapcsolat létrehozása,
- kollekciók kezelése,
- indexek létrehozása,
- CRUD műveletek végrehajtása,
- benchmark műveletek futtatása.

A rendszer a hivatalos MongoDB Node.js drivert használja az adatbázis elérésére.

A kapcsolat létrehozása során a kliens csatlakozik a MongoDB szerverhez, majd kiválasztja a megfelelő adatbázist és kollekciót.

A benchmark műveletek külön függvényekben kerültek megvalósításra:

- insert benchmark,
- find benchmark,
- filter benchmark,
- aggregation benchmark,
- update benchmark,
- indexed find benchmark.

Az indexelt keresések vizsgálatához bizonyos mezőkre indexek kerültek létrehozásra.

eXistDB kliens implementáció

Az eXistDB kezeléséhez külön kliensmodul készült. Az adatbázis elérése REST API segítségével történt.

Az implementáció során:

- HTTP kérések kerülnek küldésre,
- XML dokumentumok feltöltése történik,
- XQuery lekérdezések futnak,
- a válaszok feldolgozása automatikusan történik.

Az eXistDB-ben minden rekord XML dokumentumként kerül tárolásra.

A lekérdezések XQuery nyelv használatával valósulnak meg. Ez lehetővé teszi összetett XML alapú keresések és szűrések végrehajtását.

Példa XQuery lekérdezés:

```
for $b in collection("books")/book
where $b/year > 2015
return $b
```

Az eXistDB benchmarkok ugyanazokat a logikai műveleteket hajtják végre, mint a MongoDB benchmarkok, így az eredmények közvetlenül összehasonlíthatók.

A rendszer külön modult használ a JavaScript objektumok XML dokumentummá alakítására. Ez biztosítja, hogy azonos adatkészlet kerüljön mindkét adatbázisba.

Benchmark tesztek

A benchmark rendszer több különböző típusú adatbázis-művelet teljesítményét vizsgálja. A tesztek célja annak elemzése, hogy a MongoDB és az eXistDB hogyan viselkedik különböző terhelési helyzetekben, valamint hogyan változik a teljesítmény növekvő adatmennyiség mellett.

Minden benchmark azonos adatkészleten és azonos logikai műveletekkel futott le mindkét adatbázisban. A mérések több alkalommal kerültek végrehajtásra, majd az eredmények átlagolásra kerültek a pontosabb összehasonlítás érdekében.

Tesztkörnyezet

A benchmark tesztek azonos hardver- és szoftverkörnyezetben futottak annak érdekében, hogy az eredmények objektíven összehasonlíthatók legyenek. A mérések során mindkét adatbázis ugyanazt az adatkészletet és azonos logikai műveleteket használta.

A benchmark rendszer TypeScript és Node.js környezetben működött, az eredmények automatikusan CSV fájlokba kerültek exportálásra. A tesztek különböző méretű adathalmazokon futottak:

- 100 rekord,
- 1 000 rekord,
- 10 000 rekord,
- 50 000 rekord.

Minden benchmark több alkalommal került végrehajtásra, majd az eredmények átlagolásra kerültek a pontosabb mérés érdekében. Ez csökkentette az egyszeri rendszerterhelésből vagy háttérfolyamatokból adódó eltérések hatását.

A tesztek során az alábbi műveletek kerültek vizsgálatra:

- insert,
- find,
- filter,
- aggregation,
- update,
- indexed find.

A futási idők milliszekundumban (ms) kerültek mérésre.

Insert benchmark

Cél

Az insert benchmark célja nagy mennyiségű rekord adatbázisba történő beszúrásának teljesítményvizsgálata.

Ez a teszt jól mutatja:

- az adatbázis írási sebességét,
- a dokumentumfeldolgozás költségét,
- valamint a rendszer skálázhatóságát nagy adatmennyiség esetén.

Működés


A benchmark során a rendszer automatikusan generált könyv rekordokat helyezett el az adatbázisban.

A tesztek különböző méretű adathalmazokon futottak:

- 100 rekord,
- 1 000 rekord,
- 10 000 rekord,
- 50 000 rekord.

MongoDB esetén a rekordok BSON dokumentumként kerültek eltárolásra, míg eXistDB esetén XML dokumentumokká alakultak.

A futási idő a beszúrás megkezdése és befejezése között eltelt idő alapján került mérésre.



Eredmények és elemzés

A benchmark eredményei alapján a MongoDB minden adatmennyiség esetén jelentősen gyorsabb beszúrási teljesítményt mutatott.

Az alábbi táblázat az insert műveletek átlagos futási idejét mutatja:

Rekordszám	MongoDB átlag	eXistDB átlag
1 000	~88 ms	~8073 ms
50 000	~1456 ms	több tízezer ms

Az eredmények alapján jól látható, hogy a MongoDB írási teljesítménye sokkal jobban skálázódik nagyobb adatmennyiségek esetén.

Az eXistDB esetében különösen nagy költséget jelentett:

- az XML dokumentumok létrehozása,
- az XML feldolgozása,
- valamint a dokumentumok tárolása.

A BSON dokumentumok kezelése a MongoDB-ben lényegesen hatékonyabbnak bizonyult, ezért a beszúrási műveletek végrehajtása jóval gyorsabb volt még nagyobb adatmennyiségek esetén is.

Find benchmark

Cél

A find benchmark célja egy konkrét rekord keresési sebességének mérése.

Ez a művelet az egyik leggyakrabban használt adatbázis-funkció, ezért különösen fontos a teljesítménye. A teszt jól szemlélteti, hogy az adatbázis milyen gyorsan képes egy adott dokumentum megtalálására nagyobb adatmennyiség esetén is.

Működés

A benchmark során a rendszer egy adott könyvet keresett meg cím vagy azonosító alapján.


A keresés:

- MongoDB esetén dokumentumalapú lekérdezéssel,
- eXistDB esetén XQuery használatával

történt.

A teszt során minden futtatásnál ugyanaz a logikai keresés került végrehajtásra annak érdekében, hogy az eredmények objektíven összehasonlíthatók legyenek.

A futási idő a keresési művelet indítása és befejezése között eltelt idő alapján került mérésre.



Eredmények és elemzés

A benchmark eredményei alapján a MongoDB find műveletei szinte minden esetben konstans közeli futási időt mutattak.

Az alábbi táblázat az átlagos find műveletek futási idejét mutatja 50 000 rekord esetén:

Adatbázis Átlagos Find idő

MongoDB ~4 ms

eXistDB ~4501 ms

Az eredmények jól mutatják a MongoDB optimalizált dokumentumkeresési mechanizmusának előnyét.

A MongoDB esetében a keresések nagy adatmennyiség mellett is rendkívül gyorsak maradtak, ami a BSON dokumentumkezelés és az optimalizált indexelési rendszer hatékonyságának köszönhető.

Az eXistDB keresési teljesítménye ezzel szemben nagyobb adatmennyiségnél jelentősen romlott. Ennek fő oka, hogy az XML dokumentumok feldolgozása és bejárása nagyobb memória- és processzorigénnyel jár.

A benchmark alapján megállapítható, hogy a MongoDB dokumentumalapú keresései lényegesen gyorsabban végrehajthatók voltak, különösen nagy méretű adatállományok esetén.

Filter benchmark

Cél

A filter benchmark célja feltételes lekérdezések teljesítményének vizsgálata.

A teszt azt elemzi, hogy az adatbázis milyen hatékonyan képes különböző feltételek alapján rekordokat szűrni. Az ilyen típusú műveletek gyakran fordulnak elő valós alkalmazásokban, ezért kiemelten fontos a teljesítményük.

A benchmark különösen jól mutatja:

- a lekérdező motor hatékonyságát,
- a dokumentumok feldolgozásának költségét,
- valamint az adatbázis viselkedését nagyobb adatmennyiségek esetén.

Működés

A benchmark során különböző feltételek kerültek alkalmazásra, például:

- évszám alapú szűrés,
- ár szerinti szűrés,
- értékelés szerinti szűrés.

Példa feltételek:

rating > 4.5

year > 2015

A tesztek során mindkét adatbázis ugyanazokat a logikai feltételeket használta.

MongoDB esetén a szűrések dokumentumalapú lekérdezésekkel történtek, míg eXistDB esetén XQuery alapú feltételes lekérdezések kerültek végrehajtásra.

A futási idő a lekérdezés indítása és befejezése között eltelt idő alapján került mérésre.

Eredmények és elemzés

A benchmark eredményei alapján a MongoDB a legtöbb esetben gyorsabban hajtotta végre a szűrési műveleteket.

A MongoDB teljesítménye különösen nagyobb adatmennyiségek esetén bizonyult kedvezőbbnek, mivel a dokumentumalapú lekérdezések és az indexelési mechanizmus hatékonyabban kezelték a feltételes kereséseket.

Az eXistDB teljesítményét negatívan befolyásolta:

- az XML dokumentumok feldolgozási költsége,
- az XML struktúrák bejárása,
- valamint az XQuery alapú lekérdezések nagyobb erőforrásigénye.

A benchmark eredményei alapján megállapítható, hogy a MongoDB szűrési műveletei jobban skálázódtak növekvő adatmennyiség mellett, míg az eXistDB futási ideje jelentősebben növekedett nagyobb adatállományok esetén.

Aggregation benchmark

Cél

Az aggregation benchmark célja összesítő műveletek teljesítményének vizsgálata.

Az aggregációs műveletek összetettebb adatfeldolgozást igényelnek, ezért jól mutatják az adatbázis lekérdező motorjának hatékonyságát és az összetett lekérdezések végrehajtási teljesítményét.

A benchmark célja annak elemzése, hogy az adatbázisok milyen hatékonyan képesek:

- átlagok számítására,
- rekordok csoportosítására,
- valamint összesítő statisztikák előállítására.

Működés


A benchmark során különböző aggregációs műveletek kerültek végrehajtásra, például:

- átlagos könyvár számítása,
- műfajonkénti csoportosítás,
- értékelések átlagolása.

MongoDB esetén az aggregációk aggregation pipeline segítségével történtek, míg eXistDB esetén XQuery alapú összesítő lekérdezések kerültek végrehajtásra.

A teszt során mindkét adatbázis ugyanazokat a logikai műveleteket hajtotta végre azonos adathalmazokon.

A futási idő a lekérdezések indítása és befejezése között eltelt idő alapján került mérésre.



Eredmények és elemzés

Az aggregációs műveleteknél kisebb különbségek figyelhetők meg, azonban a MongoDB aggregation pipeline megoldása továbbra is gyorsabbnak bizonyult.

Az alábbi táblázat az aggregációs műveletek átlagos futási idejét mutatja 50 000 rekord esetén:

Adatbázis	Aggregation átlag
-----------	-------------------

MongoDB	~81 ms
---------	--------

eXistDB	~1186 ms
---------	----------

Az eredmények alapján megfigyelhető, hogy a MongoDB hatékonyabban kezelte az összesítő műveleteket nagyobb adatmennyiségek esetén is.

A MongoDB aggregation pipeline rendszere optimalizáltabban hajtotta végre:

- a csoportosításokat,
- az átlagolásokat,
- valamint az összesítő statisztikai műveleteket.

Az eXistDB esetében az XML alapú feldolgozás nagyobb overheadet jelentett, ami növelte a futási időt. Az XML dokumentumok bejárása és az XQuery alapú aggregációk több feldolgozási lépést igényeltek.

Ennek ellenére az eXistDB jól kezelte az összetettebb XML alapú lekérdezéseket, különösen hierarchikus dokumentumszerkezetek esetén.

Update benchmark

Cél

A teszt azt mutatja meg, hogy az adatbázis milyen gyorsan és hatékonyan képes meglévő dokumentumok frissítésére. Az update műveletek különösen fontosak olyan rendszerekben, ahol az adatok gyakran változnak vagy folyamatos módosításra szorulnak.

A benchmark segítségével vizsgálható:

- a dokumentummódosítás sebessége,
- az adatbázis frissítési mechanizmusának hatékonysága,
- valamint a különböző adattárolási modellek módosítási költsége.

Működés

A benchmark során meglévő rekordok bizonyos mezői kerültek módosításra, például:

- ár,
- értékelés,
- oldalszám.

A teszt során mindkét adatbázis ugyanazokat a logikai módosítási műveleteket hajtotta végre azonos adathalmazokon.

A futási idő a módosítási művelet indítása és befejezése között eltelt idő alapján került mérésre.

Eredmények és elemzés

A benchmark eredményei alapján a MongoDB update műveletei gyorsabbnak bizonyultak.

A MongoDB teljesítményelőnye elsősorban az alábbi tényezőknek köszönhető:

- BSON dokumentumkezelés optimalizáltsága,
- gyors indexelési mechanizmus,
- kisebb XML feldolgozási overhead,
- valamint hatékonyabb dokumentummódosítási rendszer.


Az eXistDB esetében a dokumentumok módosítása nagyobb költséggel járt, mivel az XML struktúrák frissítése összetettebb feldolgozást igényelt.

Az XML dokumentumok módosítása során:

- a dokumentumstruktúra bejárása,
- az XML elemek feldolgozása,
- valamint az újrastrukturálás

további feldolgozási terhelést jelentett.

A benchmark eredményei alapján megállapítható, hogy a MongoDB hatékonyabban kezelte a gyakori módosítási műveleteket, különösen nagyobb adatmennyiségek esetén.



Indexed Find benchmark

Cél

A teszt azt elemzi, hogy az indexek milyen mértékben képesek csökkenteni a lekérdezések futási idejét, valamint hogyan befolyásolják az adatbázis teljesítményét nagyobb adatmennyiségek esetén. Az indexelés az egyik legfontosabb optimalizációs technika adatbázis-rendszerekben, ezért különösen fontos annak vizsgálata, hogy milyen teljesítményjavulást eredményez a keresési műveletek során.

Működés

A benchmark során a keresések:

- index nélkül,
- majd index létrehozása után

is lefutottak.

Az indexek elsősorban a gyakran keresett mezőkön kerültek létrehozásra, például:

- title,
- genre,
- year.

A tesztek során ugyanazok a keresési műveletek kerültek végrehajtásra mindkét esetben, így pontosan mérhetővé vált az indexelés hatása.

MongoDB esetén az indexek a dokumentumalapú kereséseket optimalizálták, míg eXistDB esetén az XML dokumentumok feldolgozása továbbra is nagyobb költséget jelentett.

A futási idő a keresési művelet indítása és befejezése között eltelt idő alapján került mérésre.

Eredmények és elemzés

A benchmark eredményei alapján az indexek jelentősen csökkentették a keresési időt.

Különösen nagy adatmennyiségnél vált jól láthatóvá az indexelés előnye, mivel index nélkül a keresési műveletek futási ideje jelentősen növekedett.

A MongoDB indexelési rendszere rendkívül hatékonyan működött, ezért az indexed find benchmarkok futási ideje szinte konstans maradt még nagyobb rekordmennyiség esetén is.

Az indexelés előnyei különösen az alábbi területeken voltak megfigyelhetők:

- gyorsabb rekordkeresés,
- kisebb lekérdezési idő,
- jobb skálázhatóság,
- stabilabb teljesítmény nagy adatállományok esetén.

Az eXistDB esetében az XML dokumentumok feldolgozási költsége továbbra is jelentős maradt, ezért az indexelés hatása kevésbé volt látványos, mint MongoDB esetén.

A benchmark eredményei alapján megállapítható, hogy az indexelés kritikus szerepet játszik a keresési teljesítmény optimalizálásában, különösen nagy méretű adatbázisok esetén.

Általános megfigyelések

A benchmark eredmények alapján több fontos következtetés vonható le a MongoDB és az eXistDB teljesítményével kapcsolatban.

A mérések azt mutatták, hogy a MongoDB szinte minden vizsgált művelet esetén jobb teljesítményt nyújtott, különösen nagyobb adatmennyiségek mellett. A különbség leginkább az insert, find és indexed find műveleteknél volt jelentős.

Az eredmények alapján megállapítható, hogy:

- a MongoDB jelentősen jobb teljesítményt nyújtott általános CRUD műveletekben,
- az eXistDB teljesítménye nagy adatmennyiségnél erősen romlott,
- az XML alapú adattárolás nagyobb feldolgozási költséget jelentett,
- a MongoDB skálázhatósága kedvezőbbnek bizonyult,
- az indexelés kritikus szerepet játszott a keresési teljesítmény javításában.

A diagramok alapján jól látható, hogy a MongoDB futási ideje sokkal lassabban növekedett az adatmennyiség emelkedésével. Ez arra utal, hogy a MongoDB hatékonyabban képes kezelni nagyobb adatállományokat és nagyobb terhelést.

A MongoDB teljesítményelőnye elsősorban az alábbi tényezőknek köszönhető:

- optimalizált BSON dokumentumkezelés,
- gyors dokumentumalapú lekérdezések,
- hatékony indexelési mechanizmus,
- valamint kisebb feldolgozási overhead.

Az eXistDB ugyanakkor bizonyos területeken továbbra is előnyös lehet, különösen olyan rendszerekben, ahol:

- az XML dokumentumok natív kezelése fontos,
- összetett hierarchikus dokumentumstruktúrák szükségesek,
- szabványos XML feldolgozásra van szükség,
- vagy XQuery alapú lekérdezések használata előnyös.

Az XML alapú adattárolás előnye a strukturált dokumentumkezelés és a szabványos adatsereformátum támogatása, azonban ez jelentős teljesítménybeli többletköltséggel járhat nagyobb adatmennyiségek esetén.

A benchmark eredmények összességében azt mutatják, hogy általános célú, nagy teljesítményű adatkezelésre a MongoDB kedvezőbb választásnak bizonyult. Az eXistDB elsősorban speciális XML alapú alkalmazási területeken lehet versenyképes megoldás.

Összegzés

A projekt során sikeresen megvalósult a MongoDB és az eXistDB összehasonlító teljesítményvizsgálata különböző benchmark tesztek segítségével. A rendszer képes volt automatikusan generált adathalmazokon futtatni az insert, find, filter, aggregation, update és indexed find műveleteket, majd az eredményeket CSV formátumban rögzíteni és diagramok segítségével elemezni.

A benchmarkok célja annak vizsgálata volt, hogy a dokumentum-orientált BSON alapú adattárolás és az XML alapú dokumentumkezelés milyen teljesítménykülönbségeket eredményez különböző adatkezelési feladatok esetén.

A mérések alapján a MongoDB szinte minden vizsgált műveletben jobb teljesítményt nyújtott. A legnagyobb különbség:

- a nagy mennyiségű adat beszúrásánál,
- az egyszerű keresési műveleteknél,
- valamint az indexelt lekérdezéseknél

volt megfigyelhető.

A MongoDB előnye elsősorban:

- az optimalizált BSON dokumentumkezelésből,
- a gyors indexelési mechanizmusból,
- valamint a hatékony lekérdező motorból

adódott.

Az eXistDB ugyanakkor jól kezelte az XML alapú dokumentumokat és az összetett XQuery lekérdezéseket. Ez különösen olyan rendszerekben lehet előnyös, ahol:

- hierarchikus dokumentumszerkezetek kezelése szükséges,
- szabványos XML feldolgozásra van szükség,
- vagy az adatok természetes formátuma XML.

A benchmark eredmények alapján megállapítható, hogy:

- a MongoDB gyorsabb általános CRUD műveletekben,
- az eXistDB előnyös XML alapú dokumentumkezelésnél,
- az indexelés kritikus szerepet játszik a teljesítményben,
- valamint a megfelelő adatbázis kiválasztása nagymértékben függ az alkalmazási területtől és az adatok szerkezetétől.

A projekt során elkészült benchmark rendszer könnyen bővíthető további adatbázisokkal és benchmark tesztekkel, így alkalmas lehet további teljesítményvizsgálatok elvégzésére is.

Összességében a projekt jól szemléltette a különböző NoSQL adatbázis-megközelítések közötti eltéréseket, valamint azt, hogy az adattárolási modell jelentős hatással van a rendszer teljesítményére, skálázhatóságára és erőforrásigényére.

<https://github.com/balazsfoldi/mongodb-existdb-benchmark>